

Program report

這次作業 GPT 不推薦我用前兩次作業的

hypothesis 學習法，而是使用“隨機森林

(Random Forest) 學習法

(1) Classification :

data set : 整個 xml 的所有資料，

資料內容 : (x, y) $\rightarrow \begin{cases} 0, \text{溫度} = -999 \\ 1, \dots, \neq -999 \end{cases}$
 $\uparrow$
特徵 (經緯度)

60% training set

20% validation set

20% test set

(2) model : Random forest

樹的數量 : 100

max-depth : model 自行尋找最佳深度

隨機種子 : 42

(use scikit-learn's RandomForestClassifier)

訓練方法 : Bagging (自助抽樣法)

學習方法簡述：每棵樹各自學習

分類規則，最終以多數決決定結果

(b) Result


```
Python 3.7.4 (tags/dirty: (base python 3.7.4) + assignment 4) [python 3.7.4] (class)
驗證集準確率: 0.9838
測試集準確率: 0.9807
--- 以缺值定義的邊界錯誤分析 ---
邊界區域準確率: 0.8361 (樣本數: 61)
非邊界區域準確率: 0.9864 (樣本數: 1547)
請輸入經度,緯度 (例如 120.5,23.5, 或直接按 Enter 結束):
```

可輸入經緯度，輸出預測值 & 實際值
test data 準確率為 0.9807 (感覺還行?)
邊界區域的準確率略低


(邊界區域為若一點本身有溫度，而上下左右任一點溫度為 -999，則為邊界點。)

非邊界出錯個人猜測主要為邊界點靠附近一兩格的非邊界點預測失誤
(由下圖可知)

validation



test



(2)

data set : xml 中全部資料

training : validation : test = 6 : 2 : 2

資料內容： (x, y) $\begin{matrix} \nearrow \text{溫度} \\ \downarrow \text{經緯度} \end{matrix}$

model : same as (1)

loss = MSE

Result :

```
PS C:\Users\danie\Desktop\ml\assignment 4> python '.\Regression code.py'
```

驗證集 MSE: 5.7009
測試集 MSE: 5.6295
請輸入經度, 緯度 (例如 120.5, 23.5, 或直接按 Enter 結束) :

可輸入經緯度，輸出預測溫度&實際溫度。

MSE: 5.6295 (比想像中大)

推測原因：各地區氣候、海拔情況不一，溫度可能較沒連續性，因此預測值和實際值有落差。

