

Week 1:

(1) 上課有提到房價模型有可能會有負的房價

老師有提到可能可以用 $h(x_1, x_2) = \sigma(b + x_1 w_1 + x_2 w_2)$

$$\sigma(x) = \frac{1}{1+e^{-x}}, \text{ 假設 } x_1=0, x_2=0$$

可能房價還是 > 0 ，不知道 $b + w_1 x_1 + w_2 x_2$

重新設計 能不能解決這問題

(2)

data 需要分

data 需要分

- (1) training set
- (2) validation set
- (3) test set

不知道三者佔比的比例不同，會不會

導致 training 的模型結果有很大差距?

(1) 可以使用 $\hat{y} = \exp(f(x))$, softplus , $\text{ReLU} + \text{正平移}$ 等

(2) training set 太小 $\Rightarrow$ 高偏差, 欠拟合

validation / test 太小 $\Rightarrow$ 評估結果方差大

常用: 70/15/15 or 60/20/20

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning.

為統計學/機器學習的經典教科書。涵蓋交叉驗證、模型選擇、偏差-變異 (bias-variance) 探討，對理解為何切分、驗證會影響結果很有幫助。

Week 2

(2)

In likelihoodly approach, if the function is Not normal distribution, the loss will be big or small for each type of real function.
(polynomial, $\sin x$, $\cos x$)

不同 real function, loss 差距不同

以 SSE 衡量下:

$\sin x, \cos x$: π 範圍小 $\Rightarrow$ 誤差小
" 大 $\Rightarrow$ " 大

↙ 趨近 linear

↗ 非線性

polynomial: 用高次去擬合, 誤差小

White, H. (1982). "Maximum Likelihood Estimation of Misspecified Models." *Econometrica*.

經典關於在模型被錯誤指定 (包括誤差分布不對) 時最大概似估計的漸近性質與推論修正。直接回答「當假設與真實分布不同會發生什麼」的理論問題。


Week 3

2,

by 上課筆記

Classification

data $\{(\vec{x}_i, c_i)\}$ $c_i \in [0, 1]$



Method 1: Find a func: $\mathbb{R}^2 \rightarrow \mathbb{R}$

s.t. $H(\vec{x}_i) = c_i$ (可能在交界學不好)

Method 2: One-hot encoding

$c_i \in \{[0], [1]\}$, Find a func $\mathbb{R}^2 \rightarrow \mathbb{R}^2$

s.t. $H(\vec{x}_i) = c_i$ (得勝說比較好 but don't know why)



老師是不是

還沒有說為什麼比較好

1) = 維使正類跟負類有自己的偏移、
權重, 能更快更好的定位邊界。
(softmax + cross-entropy with logits)

C. M. Bishop, "Pattern Recognition and Machine Learning", 2006.

(第4章: Logistic/softmax 與負對數似然, 解釋 link function 與多類邏輯迴歸的差異)

Week 4 (1)

$$\nabla_{\theta} \text{Loss} = \left(\frac{-y}{h_{\theta}(x)} + \frac{1-y}{1-h_{\theta}(x)} \right) \nabla_{\theta} h_{\theta}(x) = \frac{h_{\theta}(x) - y}{h_{\theta}(x)(1-h_{\theta}(x))} \nabla_{\theta} h_{\theta}(x) = (\sigma(\theta^T x) - y)x.$$

So the SGD algorithm gives

$$\theta_{n+1} = \theta_n - \eta(\sigma(\theta^T x) - y)x = \theta_n + \eta(y - \sigma(\theta^T x))x.$$



想問，這個符號是什麼

A = logistic loss 的梯成

Robbins, H. & Monro, S. (1951). "A stochastic approximation method."

Week 5

(3) unknown problem

一開始修機器學習，都會想做一個程式可以幫我打遊戲（每日任務等等），但近期學習的內容感覺做不出來。感覺不是一個線性函數可以做到的，但不確定 Assignment 4 的 random forest 有機會（？動態遊戲可能沒辦法，不過象棋、西洋棋的可能有機會？）

- 若目標是「自動化日常任務／按一定規則操作」，可先用規則式或監督式學習（行為克隆）做基線。
- 若是需要在環境中長期規劃或面對隨機性／回饋（例如打怪、走位、複雜策略），比較合適的是強化學習（RL）或 imitation learning / self-play（對弈類如象棋可用 MCTS + NN）。
- 隨機森林不太適合直接做序列表決或有長期回報的動態任務；它比較適合做每一步的靜態判斷或狀態分類。

D. A. Pomerleau (1989). ALVINN: An Autonomous Land Vehicle in a Neural Network.

說明：行為克隆（behavior cloning）早期實務案例，示範用 supervised learning 模仿人類駕駛。

Week 6

(1) GDA 的好處就是不用迭代可以做很快
但 model 的精準性如果情況
複雜就很難高，感覺沒辦法
運用在遊戲的判斷 or 下棋的
選擇，或是有其他方法將 GDA
運用進去呢？

重點摘要

- GDA 本質是「靜態的生成式分類器」，適合做「給定當前 state 預測 discrete action / 類別」的任務（即行為克隆 / supervised policy）。優點：訓練快速、參數少、機率輸出直觀；缺點：假設 class-conditional 為 Gaussian，對非線性/多模分佈表現差，且不直接處理時間序列/延遲回報（reinforcement learning）的長期規劃。
- 在簡單或結構化的遊戲（例如某些回合制、state 經過精心設計、動作空間離散且樣本不多）可作為很好的 baseline 或快速 prototype；在即時、複雜或高維影像輸入的遊戲上，直接用 GDA 通常不足，需要配合特徵工程或做為複合系統的一部分。

適用場景（何時值得一試）

- 動作是離散的（有限種類），且每一步的最佳動作大多由「當前數個觀察值」即可決定（短期依賴）。
- State 空間經過特徵工程後維度不高、比較近似 Gaussian 分佈（或可透過轉換接近）。
- 需要非常快速訓練與推論（例如在 edge 裝置或做大量 baseline 比較）。
- 想要一個解釋性高且能輸出 class posterior 的模型（方便 debug、visualize、calibrate）。

主要限制與風險

- 時序依賴/延遲回報：GDA 沒有 Internal memory，不考慮未來回報（非 RL）。若遊戲需要規劃或長期回報，GDA 無法直接學好策略。
- 非線性/多模分佈：若同一狀態下有多個合理動作（multi-modal policy），單一 Gaussian 或線性邊界會失效。
- 高維輸入：像 raw image，需要大量特徵工程或先用 CNN 提取 embedding，再用 GDA 作 classifier。
- 假設違反（不同類別共變異不同 vs 共用 covariance）：可選擇 LDA (shared covariance) 或 QDA (不同 covariance)；估計 covariance 會在樣本不足時不穩定。

Argall, B. D., Chernova, S., Veloso, M., & Browning, B. (2009). A survey of robot learning from demonstration. *Robotics and Autonomous Systems*.


說明：模仿學習（learning from demonstration）的綜述，涵蓋行為克隆、inverse RL 等方法與限制。

Week 8

3. Unanswered Questions

There are unanswered questions from the lecture, and there are likely more questions we haven't covered.

上課有一個圖



有辦法用 $p(x)$ 反推出發點嗎？

若有多個出發點如何反推？

A: 其實後面課程有講到

就是 reverse SDE 做的事

Anderson, T. W. (1982). "Reverse-time diffusion processes."

(2)

上次作業有提到我想試著做全自動的交通網路，但上次的模型化不是想的很清楚導致有點空泛，這次我想把問題聚焦每個路口的車流預測。我認為對AI來說預測未來路線的車流是必須的，才能判斷是否需要提前分流或主動讓道等等(若有緊急情況像救護車等)，所以想先嘗試做路口的車流預測分析。

Input data:

$$X_t = \{ \underset{\uparrow}{x_t^1}, x_t^2, x_t^3, \dots, x_t^N \}$$

在 t 時間點的資料

(預計有, 車速, 車流量, 車道佔用率, 天氣...)

餵給機器 L 時間的資料

$$X_{t-L+1} \sim X_t$$

Output data: $\hat{X}_{t+1}$ ($t+1$ 時間點的情況)

或是 $\hat{X}_{t+1} \sim \hat{X}_{t+H}$ (未來 H 時間的預測)

$$\text{Model} = \text{GNN} + \text{LSTM}$$

X_t : 如上面 input data 所述

A : 路線連接矩陣

$$\text{GNN} : H_t = \text{GNN}(X_t, A)$$

$$\text{LSTM} : z_t = \text{LSTM}(H_t)$$

$$\text{Linear} : \hat{x}_{t+1} = Wz_t + b$$

$$\text{Loss} = L_{\text{MAE}} = \frac{1}{NH} \sum_{i=1}^N \sum_{h=1}^H |\hat{x}_{t+h}^i - x_{t+h}^i|$$

困難：不確定查不查的到資料

當訓練集。